Práctica 1: Tipología y ciclo de vida de los datos

WebScraping

Creación de un dataset con información alquiler de viviendas a partir de los datos recogidos de la web Fotocasa y la API Idealista

Autores

María Ángeles Fuentes Expósito

Norberto Jesús de la Cruz Falcón

1. Contexto.

A la hora de buscar pisos de alquiler son de gran ayuda los portales web [13] [14] como **Fotocasa [5]**, **Habitaclia [7]** o **Idealista [6]** que ofrecen información sobre viviendas en venta y alquiler. Recolectamos esta información para poder estudiar y comparar la rentabilidad de las zonas de la ciudad de Barcelona a lo largo del tiempo en los que se recogen los datos.

Web	Descripción	Conclusión	Método extracción
Fotocasa.es	Página web generada de forma dinámica para la compraventa, alquiler y compartición de viviendas.	Se han empleado técnicas de WebScrapping que tienen en cuenta el carácter dinámico de la web.	Python Script: WebScraping.
Idealista.com	Portal web de compraventa y alquiler de vivienda con una API para consultar datos sobre las viviendas anunciadas.	Solicitamos acceso a la API para este proyecto y fue aceptado.	Python Script : API + token.

2. Título.

El dataset **BCN_viviendas_alquier_precio.csv** contiene información sobre inmuebles en Barcelona de diferentes fuentes

3. Descripción del dataset.

El conjunto de datos extraído contiene información detallada sobre viviendas en alquiler en la ciudad de Barcelona. Los datos se obtuvieron de dos principales portales web inmobiliarios en España: **Fotocasa.es e Idealista.com.** Entre la información sobre cada vivienda se incluye: precio, dimensión, número de habitaciones...

4. Representación gráfica.

El dataset generado se ha construido mediante técnicas de *webscraping* del portal Fotocasa y peticiones / consultas a API *rest* oficial de Idealista.

Como puede verse en la figura siguiente, el *dataset* contiene campos extraídos de las webs y otros que se han generado durante la exportación de los datos para dotarlo de información útil como identificadores únicos, fecha de extracción y clasificación de los registros mediante el campo Portal_web.

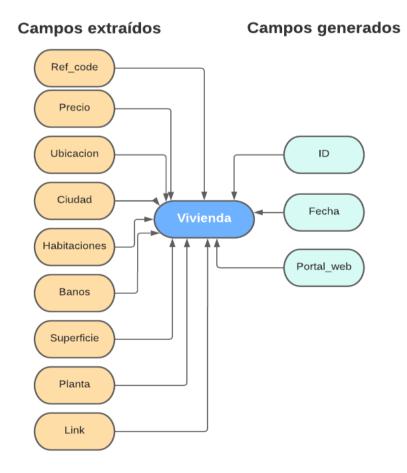


Ilustración 1 Dataset: grafo con la estructura del conjunto de datos generado

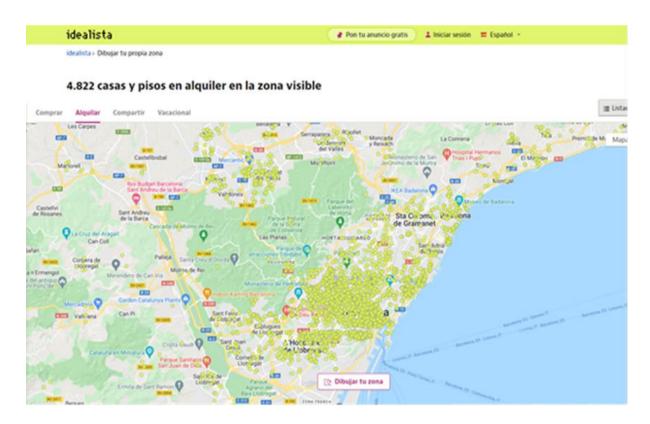


Ilustración 2 Idealista: mapa de pisos en alquiler que recogemos en nuestro dataset

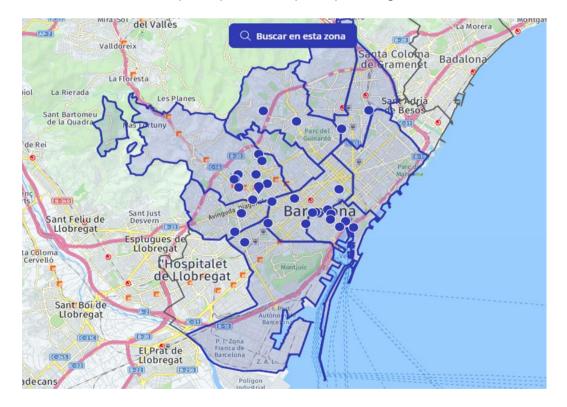


Ilustración 3 Fotocasa: mapa de pisos en alquiler que recogemos en nuestro dataset

5. Contenido.

Los datos extraídos hacen referencia a viviendas de alquiler en la ciudad de Barcelona.

Investigación previa:

Antes de comenzar el desarrollo de la práctica, analizamos los sitios web que pudieran ofrecernos la información que cumpliera con nuestro objetivo "Estudio descriptivo de la rentabilidad de la zona de Barcelona."

Elegidos los portales inmobiliarios, analizamos sus políticas

 el archivo robots.txt: el archivo robots.txt de cada portal indica las restricciones a tener en cuenta cuando vamos a rastrearlos. Las hemos de tener en cuenta para reducir la posibilidad de ser bloqueado.

A continuación, se muestran algunos ejemplos de restricciones o permisos definidos en los archivos robots.txt de cada portal web.

Idealista

https://www.idealista.com/robots.txt

Exclusión de acceso robots a las páginas concretas:

```
User-agent: *
# pro
Disallow: /pro/*/listingDispatcherController$
Disallow: /ajax/*
Disallow: /*.ajax$
[...]
# paginacion
# Disallow: /*/pagina-
Disallow: /*/pagina-*.htm
```

Fotocasa

https://www.fotocasa.es/robots.txt

Permiso de acceso a los robots:

```
User-agent: Mediapartners-Google
Allow: /
User-agent: AdsBot-Google
Allow: /
User-agent: AdsBot-Google-Mobile
Allow: /
User-agent: TwitterBot
Allow:/
```

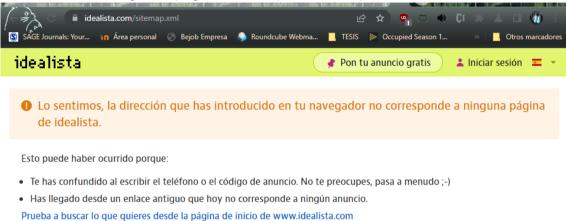
Exclusión de acceso robots a las páginas concretas:

```
User-agent: *
#pagination
Disallow: */1/4*
Disallow: */1/5*
Disallow: */1/6*
```

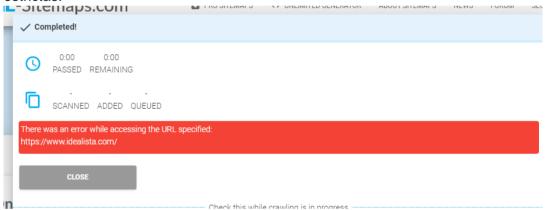
2) el mapa del sitio web:

Idealista

No encontramos el sitemap de la página de Idealista, al intentar escribir en el buscador, nos redirige a la página de error por defecto que mostramos a continuación:



El portal web Idealista no permite la generación del sitemap por sus políticas más estrictas.



Y nos bloquea el acceso IP que podemos recuperar rellenando un CAPTCHA.

idealista

Vaya! parece que estamos recibiendo muchas peticiones tuyas en poco tiempo
Para ver que realmente eres tú y no un maligno robot, te pedimos que hagas la siguiente validaci

No soy un robot

¿Por qué esta verificación? Algo sobre el comportamiento del navegador nos ha intrigado.

Varias posibilidades:

- usted navega y hace clic a una velocidad sobrehumana

- algo bloquea el funcionamiento de JavaScript en su ordenador

Ilustración 1 Validación No soy un Robot en Idealista

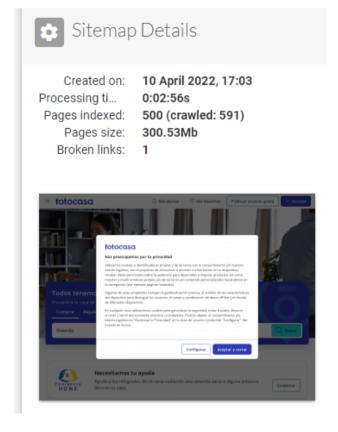
Fotocasa

https://www.fotocasa.es/sitemaps/sitemap_index_fotocasa_v2.xml

Ilustración 2 Extracto SiteMaps de Fotocasa

A continuación mostramos los detalles del Sitemap generado con la herramenta Xml-SiteMaps [19] donde podemos ver el número de páginas indexadas y el tamaño de la web 300.53Mb

https://www.xml-sitemaps.com/download/fotocasa.es-d3a28a99/sitemap.html?view=1



3) la tecnología usada: Idealista

Fotocasa

4) **el propietario** del mismo: **Idealista**

```
import whois
print(whois.whois('https://www.idealista.com/'))
```

La función whois llama al sitio web y nos da la información del propietario. El resultado se puede ver a continuación:

```
"domain name": "IDEALISTA.COM",
"registrar": "DonDominio (SCIP)",
"whois server": "whois.scip.es",
"referral url": null,
"updated date": [
"2021-07-20 08:19:18",
"2021-07-20 10:20:31"
"creation date": "1999-08-21 21:28:24",
"expiration_date": "2023-07-15 15:55:10",
"name_servers": [
"ANYCASTI.IRONDNS.NET".
"ANYCAST2.IRONDNS.NET",
"SECI.RCODEO.NET",
"SEC2.RCODEO.NET"
],
"status": [
"clientTransferProhibited https://icann.org/epp#clientTransferProhibited",
"ok http://www.icann.org/epp#ok",
"clientTransferProhibited http://www.icann.org/epp#clientTransferProhibited"
],
"emails": [
"abuse@scip.es",
"idealista.com@whoisprivacycontact.com"
],
"dnssec": [
"unsigned",
"Unsigned"
"name": "Whois Privacy Service Protects this domain",
"org": "Soluciones Corporativas IP, c/o Whois Proxy",
"address": "C/ Menestrals 14",
"city": "Manacor",
"state": "Illes Balears",
"zipcode": "07500",
"country": "ES"
```

Fotocasa

```
import whois
print(whois.whois('https://www.idealista.com/'))
```

Por otra parte, Fotocasa no nos devuelve información sobre el propietario. Al realizar la consulta whois vemos que la respuesta no contiene información:

```
"domain name": null,
"registrar": null,
"whois server": null,
"referral url": null,
"updated date": null,
"creation_date": null,
"expiration date": null,
"name servers": null,
"status": null.
"emails": null.
"dnssec": null.
"name": null,
"org": null,
"address": null,
"citv": null.
"state": null,
"zipcode": null,
"country": null
```

Recogida de datos desde dos fuentes distintas:

Antes de comenzar a realizar web scraping, verificamos si ya existía una Api que nos permitiera recuperar la información de interés para nuestro conjunto de datos y encontramos la API oficial de Idealista, cuyo acceso fue solicitado para fines de investigación universitarios, aunque tiene limitaciones de 100 peticiones por mes, han sido suficientes para recopilar la cantidad de datos que queríamos manejar, además de ofrecernos la posibilidad de generar un dataset de forma incremental.

Se ha hecho uso de la API [15] proporcionada por Idealista para obtener la información sobre los pisos en alquiler que se anuncian en su portal web.



Ilustración 4 Email Idealista: Respuesta a nuestra solicitud para utilizar la API de Idealista.

Por otro lado, se han empleado técnicas de web scraping para recoger datos desde la página web de **Fotocasa**. El desarrollo del script del web scraping se ha empleado el lenguaje de programación *Python* y la librería *Selenium* con *ChromeDriver*.



Metodología de captura de datos

Se plantearon dos formas de recoger los datos desde Fotocasa:

- haciendo clic en el anuncio de cada vivienda en alquiler y sacando información detallada desde ahí, u
- 2. obteniendo la información que se muestra en el listado de viviendas para cada uno de ellas.

Se ha optado por la última opción para que los atributos recogidos para cada vivienda (precio, localización, número de dormitorios...) estén alineados con los valores extraídos desde la API de **Idealista**.

Los datos se han extraído durante 3 de abril de 2022 a 11 de abril de 2022.

Tecnologías utilizadas

1. Trello [8]: para la organización de la práctica se ha empleado el tablero Trello de Atlassian. Es un recurso gratuito usado en metodologías ágiles como Scrum para

- organizar y gestionar proyectos, utilizando columnas para el estado del proceso y tarjetas que definen las tareas del proyecto.
- 2. Visual Studio Code [9]: Entorno de desarrollo (IDE) gratuito para programación.
- 3. Postman [10] para probar la API de Idealista.
- 4. Notepad++ [11]: bloc de notas OpenSource que permite visualizar el contenido según el lenguaje de programación configurado. Útil para visualizar ficheros con extensión JSON y XML.
- 5. GitHub [12]: es un repositorio controlador de versiones que permite trabajar conjuntamente y en remoto entre diferentes desarrolladores. Utiliza tecnología Git.













Resultados de la recogida de datos

Los campos del dataset generado con los valores extraídos de las fuentes son los que se muestran a continuación en la Tabla siguiente.

Campo	Tipo de dato	Descripción	Ejemplo
Ref_code	Carácter	Identificador del anuncio inmobiliario	163001940
Precio	Entero	Precio del alquiler mensual	1200
Ubicacion	Carácter	Distrito o calle de Barcelona en la que se encuentra localizada la vivienda	Gràcia
Ciudad	Carácter	Ciudad en la que se ubica la vivienda	Barcelona

Habitacione s	Entero	Número de dormitorios que tiene la vivienda.	2
Banos	Entero	Número de baños que tiene la vivienda	1
Superficie	Entero	Área ocupada por la vivienda en metros cuadrados	80
Planta	Carácter	Piso en el que se sitúa la vivienda (Planta baja, primer piso)	1
Link	Carácter formato URL	Dirección al anuncio de la vivienda	https://www.foto casa.es/es/alquile r/vivienda/barcel ona-capital/aire- acondicionado- calefaccion- parking-no- amueblado/1630 o1940/d

Además de la información obtenida de cada página web, se añaden al conjunto de datos los siguientes campos:

Campo	Tipo de dato	Descripción	Ejemplo
ID	Entero	Número único que identifica a la vivienda	1
Fecha	Date (yyy-mm-dd)	Fecha en la que se ha extraído la información de la vivienda.	2022-04-03
Portal_web	Carácter	Página web desde donde se han extraído los datos de la vivienda	Fotocasa

6. Agradecimientos.

Este dataset se ha realizado gracias a la comunidad de código abierto:

- Python
- Selenium

Al repositorio y control de versiones para trabajar en equipo:

GitHub

A los portales web que tienen los datos que hemos scrapeado y utilizado su API oficial, respectivamente:

Fotocasa.es

Fotocasa es el portal inmobiliario líder de España y cuenta con 1,5 millones de inmuebles de segunda mano, promociones de obra nueva y viviendas de alquiler. Fue fundado en 1999 y lleva más de veinte años ayudando a encontrar un hogar a millones de españoles. Es un portal gratuito que pone en contacto a los arrendadores y los arrendatarios, tanto particulares como empresas inmobiliarias o profesionales.

Idealista.com

Idealista es otro portal inmobiliario líder de España y cuenta con 1,5 millones de anuncios de pisos y casas en venta o alquiler. Publicar es gratis para los dos primeros anuncios. Ofrece servicios sobre valoraciones de inmuebles, información catastral y datos del mercado inmobiliario en cualquier calle de España.

Durante la investigación previa, encontramos proyectos de scraping de Fotocasa y de Idealista que han resuelto, utilizando otras técnicas de scraping, la captura de datos de los portales y nos han servido para comparar nuestra solución:

- https://github.com/EdelBlau/PEC_TPC
- https://github.com/eambroa/WebScrapingFotocasa
- https://github.com/aazqueta/idealista-data

7. Inspiración.

Objetivo: "Estudio descriptivo de la rentabilidad de las zonas de Barcelona."

La generación de este conjunto de datos viene dado por el interés en conocer la rentabilidad de las zonas de la ciudad de Barcelona y propuesta de un estudio descriptivo.

Tras la puesta en marcha del índice de referencia de precios de alquiler, que tiene como objetivo la regularización del precio de los alquileres en Barcelona [4], podemos clasificar si los precios de alquileres recogidos cumplen con la aplicación de la Ley 11/2020, sobre las

medidas urgentes en materia de contención de rentas en los contratos de arrendamiento de la Ley 11/2020, sobre las medidas urgentes en materia de contención de rentas en los contratos de arrendamiento de vivienda.

Ahora, la nueva regulación establece que el precio de la renta de un alquiler de larga estancia no podrá ser superior al del índice de referencia de precios de alquiler.

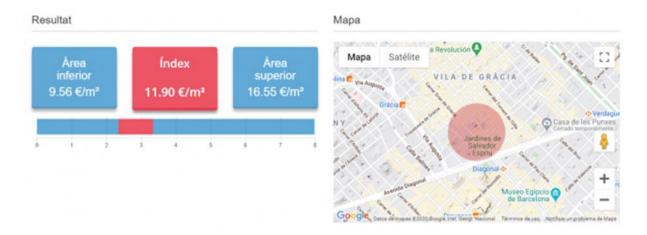


Ilustración 4 Agència de l'Habitatge de Catalunya, Gencat.cat

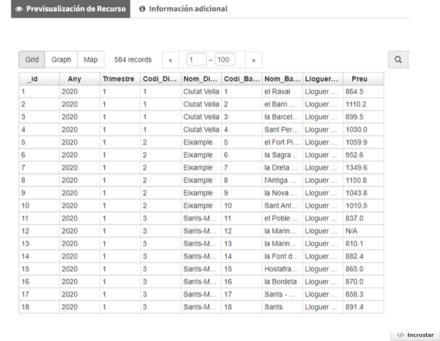
Gracias a los recursos OpenData publicados por el ayuntamiento de Barcelona, podemos conocer el histórico (desde 2014 a 2021) del precio de alquiler mensual medio de la ciudad de Barcelona. Alquiler mensual medio (€/ mes) y por superficie (€ / m2 por mes) [referencia] figura x.

Además, para analizar la rentabilidad de la zona, podemos cruzar los datos recogidos durante este proyecto con otros conjuntos de datos y ofrecer información del acceso al ocio y la cultura:

El listado de bibliotecas municipales, salas de estudio y museos [referencia]

El listado de espacios de música y copas de la ciudad de Barcelona, que incluye bares, pubs de música, coctelerías, karaoke, salas de fiesta, etc.[3]





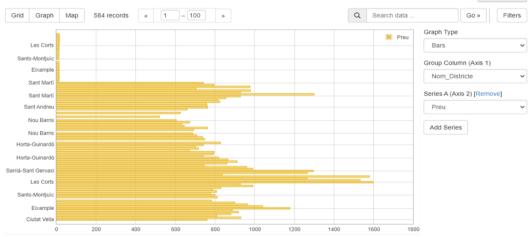


Ilustración 5 Previsualizaciones de los recursos OpenData est-mercat-immobiliari-lloguer-mitja-mensual

8. Licencia.

Fotocasa permite un uso no comercial de los datos que en su portal se muestran, tal y como se establece en el punto 3: Propiedad Industrial e Intelectual. Este hecho nos impide emplear una licencia comercial para el dataset, debiendo elegir una licencia no comercial.

3. Propiedad intelectual e industrial

El usuario reconoce que todos los elementos del Portal y de cada uno de los Servicios prestados a través del mismo, la información y materiales contenidos en el mismo, la estructura, selección, ordenación y presentación de sus contenidos y los programas de ordenador utilizados en relación con el mismo están protegidos por derechos de propiedad intelectual e industrial de Adevinta Spain o de terceros.

Salvo que fuera autorizado por Adevinta Spain o, en su caso, por los terceros titulares de los derechos correspondientes, o a menos que ello resulte legalmente permitido, el usuario no podrá reproducir, transformar, modificar, desensamblar, realizar ingeniería inversa, distribuir, alquilar, prestar, poner a disposición o permitir el acceso al público a través de cualquier modalidad de comunicación pública de ninguno de los elementos referidos en el párrafo anterior.

En particular, queda terminantemente prohibido la utilización de los textos, imágenes, anuncios y cualesquiera otro elemento incluido en el presente sitio web para su posterior inclusión, total o parcial, en otros sitios web ajenos a Adevinta Spain sin contar con la autorización previa y por escrito de Adevinta Spain.

El Usuario deberá utilizar los materiales, elementos e información a la que acceda a través de la utilización del Portal y de cada uno de los correspondientes Servicios únicamente para sus propias necesidades, obligándose a no realizar ni directa ni indirectamente una explotación comercial ni de los servicios ni de los materiales, elementos e información obtenidos a través de los mismos.

Idealista prohíbe el uso comercial de los datos que se alojan en el portal. Esta información se encuentra en el apartado 8: Propiedad intelectual e industrial de sus condiciones legales. Además, indican que si se comparte públicamente información que procede del portal, se debe reconocer a Idealista como titular de dicha información.

8.1. Materiales e información contenidos en la Web y Apps

Por las presentes Condiciones Generales, reconoces y aceptas que todos los derechos sobre los materiales y elementos que aparecen en la Web y Apps (incluyendo sin carácter limitativo, dibujos, textos, gráficos, mapas, fotografías, imágenes, audio, video, signos distintivos, logos, marcas, nombres comerciales, dominios, software etc.) pertenecen a idealista, o en su caso, a terceros que han consentido la cesión de los mismos a idealista, por lo que contamos con todos los derechos y licencias necesarias para su uso.

El hecho de que te permitamos acceder, usar, navegar, utilizar y/o descargar materiales de nuestra Web y Apps en ningún caso implica que renunciemos, o que estemos transmitiendo u concediendo una licencia o cesión de nuestros derechos, ni que adquieras titularidad sobre los mismos. Como Usuario, o como Usuario Registrado tan solo dispones de un derecho de uso estrictamente personal y privado, exclusivamente con la finalidad de disfrutar del Servicio. En consecuencia, no puedes manipular

cualquier elemento de identificación de idealista o de los respectivos titulares. En particular, queda prohibida la utilización de cualquier material o elementos de la Web y Apps para su inclusión, total o parcial, en otros sitios webs o apps ajenos sin contar con nuestra autorización previa y por escrito, y usar cualquier elemento o información de forma que diera la impresión de que los mismos pertenecen o están asociados al Usuario o Usuario Registrado.

En concreto, no está permitido revender, realizar deep-links, utilizar, copiar, monitorizar (por ejemplo, spider, scrape), mostrar, descargar, guardar o reproducir el contenido, la información, el software, los productos o los servicios disponibles en nuestro sitio web para cualquier actividad comercial o competitiva sin autorización previa y por escrito por nuestra parte.

Para cumplir con las condiciones impuestas por ambos portales (uso no comercial y atribución de las fuentes) se distribuirá el dataset bajo una licencia CC BY-NC-SA 4.0. Esta licencia prohíbe el uso comercial del *dataset* y obliga a atribuir a los autores del mismo.

Como condición adicional se podría indicar que los autores originales de los datos son los portales web Idealista y Fotocasa.

9. Código.

El código Python con el que se ha generado el dataset, se encuentra disponible en el repositorio Git: https://github.com/Angeles1/FotocasaScraping

10. Dataset.

El dataset obtenido en este proyecto se ha publicado en formato CSV en la plataforma Zenodo.

DOI: 10.5281/zenodo.6409838

Disponible en el siguiente enlace: https://zenodo.org/record/6409838

11. Referencias y bibliografía.

[1] Zonas de Barcelona - espacios música y copas

https://opendata-ajuntament.barcelona.cat/data/es/dataset/culturailleure-espaismusicacopes

[2] Zonas de Barcelona - espacios y equipamiento de Cultura y ocio

https://opendata-ajuntament.barcelona.cat/data/es/dataset/culturailleure-bibliotequesimuseus

[3] Repositorio Opendata Ajuntament Barcelona

https://opendata-ajuntament.barcelona.cat/data/es/dataset/est-mercat-immobiliari-lloguer-mitja-mensual

[4] Agencia Habitatge Generalitat Catalunya

http://agenciahabitatge.gencat.cat/wps/portal/serveis/busques%20pis%20o%20local/index-preus-de-

<u>lloguer/!ut/p/z1/pZFRT4MwEMe_ynzgsbkK7SiPxBncsqlxZkJflgIFaqAwKHP66e2MT8a5LN7b</u> 5e5-

97 7A4cYuBZ7VQqjWi1qmyd8umWPQXTHiLvETwuCQzqfRXNGPIwJbIADz7TpTAWJqLJM OPhNpq4eZL-

LKSJuWqAqDXIUUJp7cppK4vnwck4ct2V8IkJs5 m5lsSu8E-

<u>uiK5hfaHmH0C2mVngknnr23vs4QdyMXDxdclfT7AWqtfdjofWp1YbeTAQ_9soC3X71c2qtFqFqZDSRQvxNwriX1AQn0B1TcO8d6Q_noum2a4MTcKrTzu9Bsw!/dz/d5/L2dBISEvZ0FBIS9nQSEh/</u>

- [5] Fotocasa https://www.fotocasa.es/es/
- [6] Idealista https://www.idealista.com/
- [7] Habitaclia https://www.habitaclia.com/
- [8] Trello https://trello.com/
- [9] Visual Studio Code https://code.visualstudio.com/
- [10] Postman https://www.postman.com/
- [11] Notepad++ https://notepad-plus-plus.org/
- [12] Zenodo https://zenodo.org/
- [13] Las mejores webs para encontrar nuevo piso de alquiler 24 de marzo, 2022 AdslZone https://www.adslzone.net/noticias/internet/mejores-webs-encontrar-nuevo-piso-alquiler

[14] Las 15 mejores páginas web y aplicaciones para buscar piso Actualizado 17.01.2022 - CasaCocheCurro

https://www.casacochecurro.com/las-mejores-paginas-web-y-aplicaciones-para-buscar-piso.html

- [15] API Request Idealista https://developers.idealista.com/access-request
- [16] Subirats, L., Calvo, M. (2019). Web Scraping. Editorial UOC.
- [17] Masip, D. (2010). El lenguaje Python. Editorial UOC
- [18] Lawson, R. (2015). Web Scraping with Python. Packt Publishing Ltd. Chapter 2. Scraping the Data.
- [19] XML-Sitemaps https://www.xml-sitemaps.com/

Contribuciones	Firma
Investigación previa	MAFE NJCF
Redacción de las respuestas	MAFE NJCF
Desarrollo del código	MAFE NJCF